GGD 혼합(VGGMM)과 BGM의 밀도 추정 비교

다양한 분포 · 표본 수 · 실데이터와 $K_{\max}$ 분석

1 요약

CTGAN 전처리의 BGM(Gaussian 성분, rdt 설정)과, 성분을 일반화 정규분포(GGD)로 바꾸고 ELBO로 검증하는 구조 이동(병합 · 삭제 · 재정렬)을 더한 VGGMM을 같은 조건에서 비교했다. $K_{\max} = 10$은 rdt 기본값이다.

- **GGD로 표현되는 분포에서 정확도 차이가 크다.**
  - 꼬리가 두꺼운 혼합, 윗부분이 평평한 혼합, 섞인 5성분 혼합에서 VGGMM은 27번 비교에서 모두 이겼다.
  - 참 분포와의 KL은 BGM보다 중앙값 기준 15–32배 작다.
  - GGD 밖의 분포인 균등분포 블록에서도 9번 모두 이겼다(5.7배).
- **성분 수가 $K_{\max}$에 끌려가지 않는다.**
  - 참 성분이 3개인 정규 혼합에서 $K_{\max} = 5 \to 50$으로 늘리면, BGM의 유효 성분은 $5 \to 18$로 늘어난다. VGGMM은 모든 $K_{\max}$에서 3이다.
  - adult age에서는 BGM이 $5 \to 42$, VGGMM이 4–6이다.
  - BGM이 더 쓴 성분은 평가 로그우도를 높이지 못했다.
- **실데이터(표본 1.6–1.9만)에서 10개 열 중 9개 열이 3개 시드 모두 우세하다.** 나머지 1개 열도 차이가 0.001 이하다.
- **약점.**
  - 표본이 적을 때($n = 1000$의 정규 · 겹친 혼합, breast cancer $n = 284$) BGM보다 약간 나쁘다.
  - 비대칭(로그정규)과 다항 꼬리(Student-t) 분포에서는 BGM과 비슷하거나 조금 나쁘다.
  - 학습 시간은 BGM보다 길다. 중앙값 기준으로 인공 데이터에서 약 7배, 실데이터(1.6–1.9만 행)에서 약 16배이고, $K_{\max}$에 대해 거의 제곱으로 늘어난다.

2 비교 설정

BGM	sklearn `BayesianGaussianMixture`, DP 사전 $\gamma = 0.001$, $K_{\max} = 10$ (rdt `ClusterBasedNormalizer`와 같은 설정)
VGGMM	GGD 성분, $q(\tau)$ Gamma 켤레, μ, β 점추정, ELBO로 검증하는 병합 · 삭제 · 재정렬 이동, $K_{\max} = 10$
인공 분포	8종: GGD 혼합 5종(정규, 꼬리가 두꺼움, 윗부분이 평평함, 섞인 5성분, 많이 겹침)과 GGD 밖의 분포 3종(*: Student-t 혼합, 로그정규, 균등분포 블록)
표본 수와 시드	$n \in \{1000, 5000, 20000\}$, 시드 3개. 평가 데이터 2만 개는 따로 생성
실데이터	adult 6열(n = 32,561), br2000 연속 4열(n = 38,000), breast cancer 4열(n = 569). 50/50 분할, 시드 3개. 정수 열은 두 방법에 같은 디퀀타이즈를 적용
지표	인공 분포: KL= $\overline{\log p_{\text{true}}} - \overline{\log p_{\text{model}}}$(작을수록 좋음), IAE. 실데이터: 평가 표본당 로그우도(클수록 좋음). 공통: 유효 성분 수($\hat{\pi}_k > 0.005$), 학습 시간

3 인공 분포

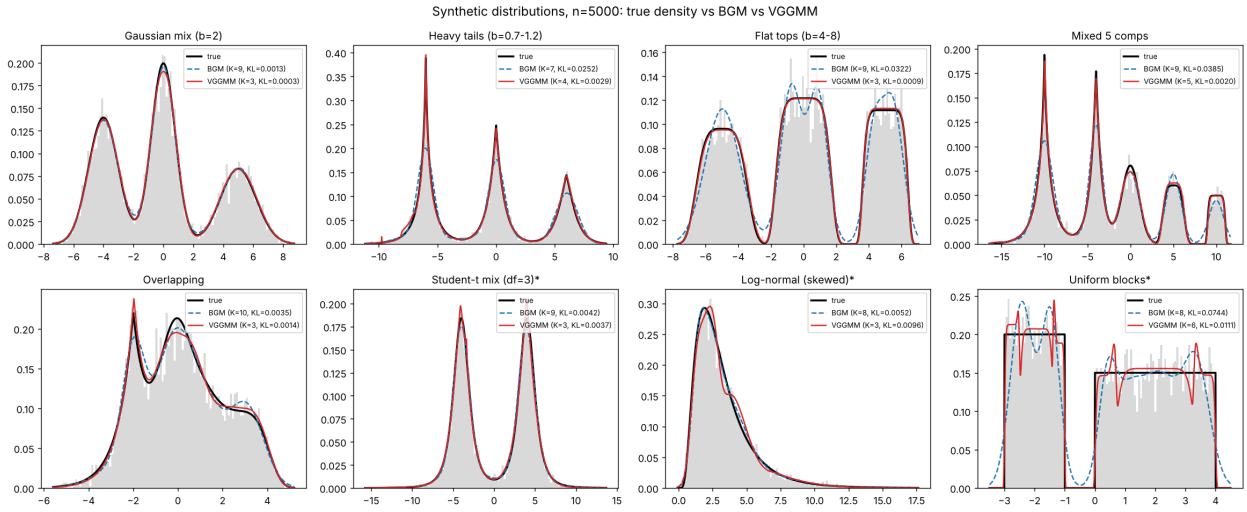


Figure 1: $n = 5000$, 시드 0. 회색은 표본 히스토그램, 검정은 참 밀도, 파란 점선은 BGM, 빨간 실선은 VGGMM이다. 범례의 K는 유효 성분 수다.

그림에서 볼 수 있듯이, BGM은 뾰족한 봉우리를 낮게 뭉개고, 평평한 윗부분을 Gaussian 여러 개로 물결처럼 흉내 내며, 상자 경계 밖으로 퍼진다. VGGMM은 형상 β로 이런 모양을 한 성분이 직접 표현한다.

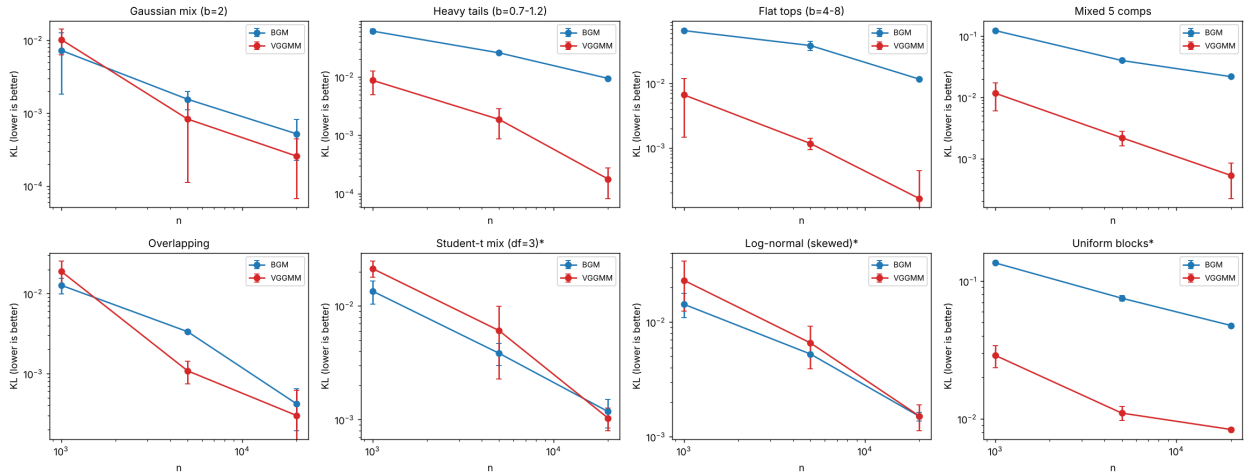


Figure 2: 표본 수에 따른 KL(로그 눈금, 시드 3개의 평균±표준편차).

정리.

- 72번 비교 중 VGGMM이 53번 이겼다(74%).
- GGD 혼합 5종에서는 45번 중 39번, GGD 밖의 분포 3종에서는 27번 중 14번 이겼다.
- 표본 수별로는 $n = 1000$에서 24번 중 12번, $n = 5000$에서 21번, $n = 20000$에서 20번 이겼다.
- VGGMM의 유효 성분 수는 참 성분 수(3 또는 5)에 가깝다. BGM은 평균 7–9개를 썼다.

분포	n	KL BGM	KL VGGMM	비율	승	K BGM	K VGGMM
Gaussian mix (b=2)	1000	0.0073	0.0103	0.6	0/3	3.3	3.0
	5000	0.0016	0.0008	2.7	3/3	8.0	3.0
	20000	0.0005	0.0003	1.9	3/3	10.0	3.0
Heavy tails (b=0.7-1.2)	1000	0.0610	0.0088	6.3	3/3	4.3	3.0
	5000	0.0259	0.0019	14.9	3/3	7.3	3.3
	20000	0.0095	0.0002	63.6	3/3	10.0	3.0
Flat tops (b=4-8)	1000	0.0659	0.0066	16.2	3/3	4.0	3.0
	5000	0.0387	0.0012	33.6	3/3	9.0	3.0
	20000	0.0116	0.0002	>100	3/3	10.0	3.0
Mixed 5 comps	1000	0.1236	0.0117	14.0	3/3	6.0	5.0
	5000	0.0402	0.0022	19.1	3/3	9.0	5.0
	20000	0.0219	0.0005	51.1	3/3	9.7	5.0
Overlapping	1000	0.0127	0.0190	0.7	0/3	5.7	2.0
	5000	0.0033	0.0011	3.1	3/3	10.0	3.0
	20000	0.0004	0.0003	2.0	3/3	10.0	3.0
Student-t mix (df=3)*	1000	0.0135	0.0213	0.8	0/3	4.0	2.0
	5000	0.0038	0.0061	1.1	2/3	9.0	3.0
	20000	0.0012	0.0010	0.9	1/3	9.7	3.7
Log-normal (skewed)*	1000	0.0143	0.0231	0.6	0/3	6.0	3.0
	5000	0.0053	0.0066	0.9	1/3	8.3	3.7
	20000	0.0015	0.0015	0.9	1/3	9.0	5.3
Uniform blocks*	1000	0.1357	0.0289	4.8	3/3	4.3	3.7
	5000	0.0752	0.0110	6.7	3/3	8.7	6.3
	20000	0.0477	0.0084	5.7	3/3	10.0	7.7

Table 1: 인공 분포 결과. "비율"은 BGM KL / VGGMM KL의 중앙값으로, 1보다 크면 VGGMM이 참 분포에 더 가깝다. VGGMM의 KL이 거의 0이면 비율이 부풀려지므로 100을 넘는 값은 >100으로 표시했다. "승"은 시드 3개 중 VGGMM의 KL이 더 작은 횟수다.

4 실데이터

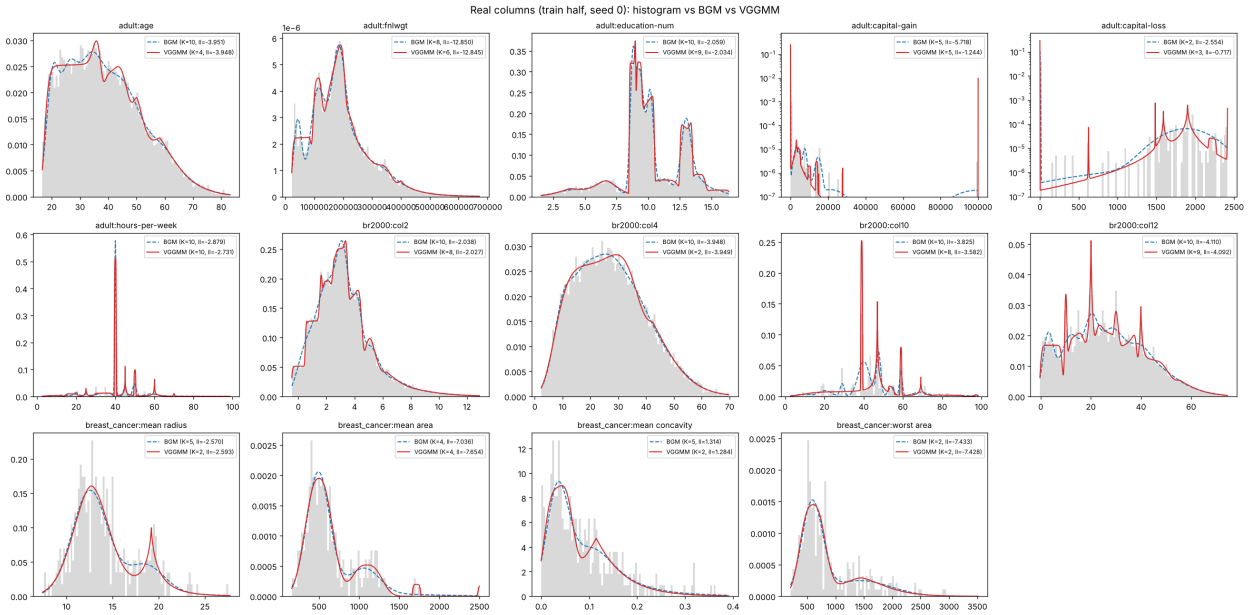


Figure 3: 학습 절반(시드 0)의 히스토그램과 두 모형의 밀도. capital-gain과 capital-loss는 0이 90% 이상이라 y축을 로그 눈금으로 그렸다.

열	n_{train}	ll BGM	ll VGGMM	차이	승	K BGM	K VGGMM	시간(s) BGM/VGGMM
adult:age	16280	-3.951	-3.947	+0.004	3/3	10.0	4.0	0.8/15.8
adult:fnlwgt	16280	-12.847	-12.841	+0.006	3/3	8.7	6.0	0.8/16.2
adult:education-num	16280	-2.069	-2.042	+0.028	3/3	10.0	9.0	0.8/11.4
adult:capital-gain	16280	-5.737	-1.261	+4.477	3/3	5.0	5.7	0.8/3.6
adult:capital-loss	16280	-2.545	-0.708	+1.838	3/3	2.3	4.0	0.7/4.4
adult:hours-per-week	16280	-2.890	-2.751	+0.139	3/3	10.0	9.7	0.9/10.8
br2000:col2	19000	-2.042	-2.030	+0.013	3/3	9.7	8.3	0.9/17.2
br2000:col4	19000	-3.948	-3.949	-0.001	0/3	10.0	2.0	0.9/14.4
br2000:col10	19000	-3.688	-3.523	+0.165	3/3	10.0	9.3	0.9/13.5
br2000:col12	19000	-4.111	-4.095	+0.017	3/3	10.0	7.7	0.9/17.7
breast_cancer:mean radius	284	-2.555	-2.563	-0.008	1/3	3.7	2.0	0.1/0.7
breast_cancer:mean area	284	-7.012	-7.217	-0.205	1/3	3.7	3.0	0.0/0.7
breast_cancer:mean concavity	284	1.359	1.350	-0.010	1/3	4.0	2.7	0.0/0.9
breast_cancer:worst area	284	-7.401	-7.410	-0.009	1/3	3.0	2.0	0.1/0.6

Table 2: 실데이터 결과(시드 3개 평균). "차이"는 VGGMM − BGM의 평가 로그우도이고, 양수이면 VGGMM이 낫다.

정리.

- 표본이 1.6–1.9만인 adult와 br2000의 10개 열에서 VGGMM은 30번 중 27번 이겼다. 진 3번(br2000 col4)도 차이는 -0.001이다.
- 차이가 큰 열은 0이 몰린 열(capital-gain +4.48, capital-loss +1.84)과 반복되는 정수값이 많은 열(hours-per-week +0.14, br2000 col10 +0.17)이다. GGD 성분이 좁은 상자나 뾰족한 봉우리를 직접 표현하기 때문이다.
- 표본이 284개인 breast cancer에서는 12번 중 4번만 이겼다. mean area에서는 VGGMM이 이상값 몇 개에 작은 성분을 붙이는 과적합이 그림으로도 보인다.

5 $K_{\max}$ 분석

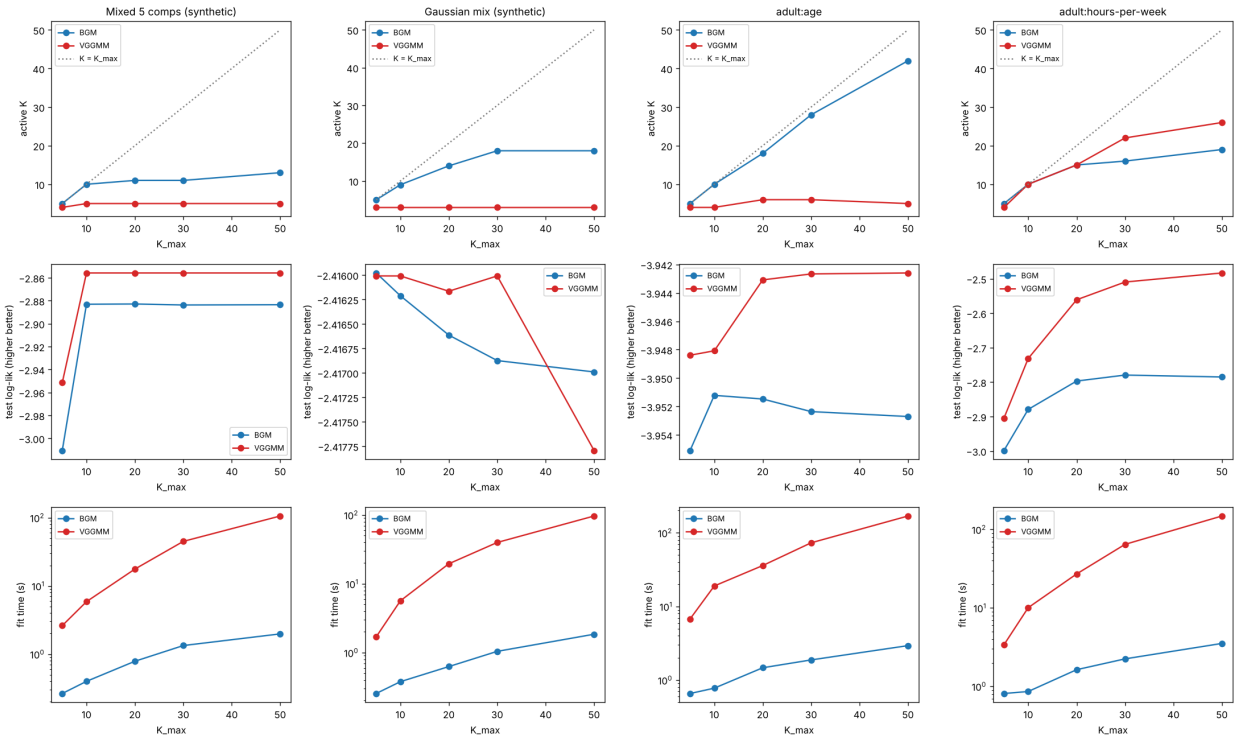


Figure 4: $K_{\max} \in \{5, 10, 20, 30, 50\}$에 따른 유효 성분 수(위), 평가 로그우도(가운데), 학습 시간(아래, 로그 눈금). 위 그림의 점선은 $K = K_{\max}$이다.

관찰.

- **5성분 혼합과 정규 혼합(인공).**
  - VGGMM은 $K_{\max} \geq 10$이면 유효 성분이 각각 5와 3으로 일정하다(참값과 같다).
  - BGM은 $10 \to 13, 9 \to 18$로 늘지만 평가 로그우도는 그대로다. 정규 혼합에서는 두 방법의 차이가 0.0002 이하다.
- **adult age.**
  - BGM은 유효 성분이 $K_{\max}$와 거의 같다($10 \to 42$). 로그우도는 오히려 조금 나빠진다($-3.951 \to -3.953$).
  - VGGMM은 4–6개이고, 로그우도는 $-3.948 \to -3.943$이다.
- **adult hours-per-week(반복되는 정수값이 많은 열).**
  - 두 방법 모두 $K_{\max}$를 따라 성분이 늘어난다. VGGMM은 $10 \to 26$, BGM은 $10 \to 19$이다.
  - 다만 VGGMM은 성분이 늘 때 로그우도가 크게 좋아진다($-2.732 \to -2.483$, BGM은 $-2.879 \to -2.785$).
  - 40, 50, 60시간처럼 반복되는 값마다 폭 1짜리 상자가 생기므로, 데이터가 실제로 많은 성분을 필요로 하는 경우다. 성분 수가 적합도 향상 없이 늘어나는 age의 BGM과는 성격이 다르다.
- **학습 시간.**
  - VGGMM은 $K_{\max} = 10$에서 6–19초, 50에서 97–169초였다.
  - BGM은 각각 0.4–0.9초와 1.9–3.5초였다.

데이터	항목	$K_{\max}=5$	$K_{\max}=10$	$K_{\max}=20$	$K_{\max}=30$	$K_{\max}=50$
Mixed 5 comps (synthetic)	BGM 유효 K	5	10	11	11	13
	BGM ll	-3.011	-2.883	-2.883	-2.884	-2.883
	BGM 시간(s)	0.3	0.4	0.8	1.3	2.0
	VGGMM 유효 K	4	5	5	5	5
	VGGMM ll	-2.951	-2.856	-2.856	-2.856	-2.856
	VGGMM 시간(s)	2.6	5.9	17.7	45.0	106.1
Gaussian mix (synthetic)	BGM 유효 K	5	9	14	18	18
	BGM ll	-2.416	-2.416	-2.417	-2.417	-2.417
	BGM 시간(s)	0.3	0.4	0.6	1.0	1.9
	VGGMM 유효 K	3	3	3	3	3
	VGGMM ll	-2.416	-2.416	-2.416	-2.416	-2.418
	VGGMM 시간(s)	1.7	5.7	19.5	39.8	96.6
adult:age	BGM 유효 K	5	10	18	28	42
	BGM ll	-3.955	-3.951	-3.951	-3.952	-3.953
	BGM 시간(s)	0.7	0.8	1.5	1.9	2.9
	VGGMM 유효 K	4	4	6	6	5
	VGGMM ll	-3.948	-3.948	-3.943	-3.943	-3.943
	VGGMM 시간(s)	6.8	19.0	36.0	73.2	169.2
adult:hours-per-week	BGM 유효 K	5	10	15	16	19
	BGM ll	-2.998	-2.879	-2.797	-2.780	-2.785
	BGM 시간(s)	0.8	0.9	1.6	2.2	3.5
	VGGMM 유효 K	4	10	15	22	26
	VGGMM ll	-2.904	-2.731	-2.561	-2.510	-2.483
	VGGMM 시간(s)	3.4	10.1	27.1	64.6	148.5

Table 3: $K_{\max}$ 비교의 수치. 학습 시간은 다른 작업 없이 단독으로 측정했다.

$K_{\max}$를 무작정 키우면 안 되는 이유.

1. **BGM:** $K_{\max}$를 늘리면 유효 성분도 함께 늘지만 평가 로그우도는 거의 그대로이거나 조금 나빠진다. CTGAN에서는 연속 열 하나가 $1+K$ 차원(정규화 값 1개와 성분 원-핫 K 개)이 되므로, 쓸모없는 성분은 생성기가 배워야 할 출력 차원만 늘린다.
2. **VGGMM:** 유효 성분 수는 $K_{\max} \geq 10$이면 거의 일정하다. 반면 계산량은 이동 탐색 때문에 $K_{\max}$에 대해 거의 제곱으로 늘어난다(5성분 데이터에서 $K_{\max}=10$일 때 5.9초, 50일 때 106초).
3. **참고:** CTGAN 구현의 기본값은 10이다. 논문에 이 값의 근거가 있는지는 이번에 확인하지 못했다.

제안. $K_{\max}=10$을 기본으로 쓰고, 유효 성분 수가 $K_{\max}$에 닿은 열에만 $K_{\max}$를 두 배로 늘려 다시 적합한다("절단 점검"). DP의 stick-breaking 절단은 쓰이지 않는 성분이 남아 있을 때 충분하다고 볼 수 있다(Ishwaran & James, 2001). 실데이터 실험($K_{\max}=10$)에서 VGGMM이 상한 10에 닿은 경우는 반복되는 정수값이 많은 hours-per-week와 br2000 col10뿐이었다. 이런 열만 $K_{\max}=20$으로 다시 적합하면, 비용은 해당 열에만 든다.

6 교수님 지적에 대한 응답

1. **"이웃을 묶는 것은 최적화가 아니다."**

- 이동은 같은 목적함수(ELBO)가 같은 반복 횟수의 대조군보다 커질 때만 받아들인다. 받아들인 뒤에도 같은 좌표 상승을 계속하므로 ELBO는 줄지 않는다.
- 하지만 어떤 후보를 시도할지(이웃 쌍, 작은 성분)는 경험적 규칙이다. 이 부분의 지적은 타당하다.

2. **"$K_{\max}$가 커지면 시간이 폭증한다."**
   - 측정 결과도 그렇다. 5성분 데이터에서 $K_{\max} = 10 \to 50$이면 시간이 약 18배 늘었다. BGM은 약 5배였다.
   - 그래서 실용 범위는 $K_{\max} \approx 10$이며, §5의 절단 점검으로 보완하는 것을 제안한다.

3. **"BGM은 켤레이므로 $K_{\max}$를 키워도 적당한 K를 찾는다."**
   - 이번 실험에서는 그렇지 않았다. 참 분포가 BGM의 모형과 정확히 같은 정규 혼합(3성분)일 때도 BGM의 유효 성분은 $K_{\max}$를 따라 $5 \to 18$로 늘었다. adult age에서는 $5 \to 42$였다.
   - 켤레성은 반복 한 번을 빠르게 해 주지만, 변분 최적화가 국소 최적에서 빠져나오게 해 주지는 않는다.

7 결론과 다음 단계

VGGMM은 첨도가 Gaussian과 다른 분포(두꺼운 꼬리, 평평한 봉우리, 0이나 정수값에 몰린 열)에서 BGM보다 참 분포에 훨씬 가깝게 맞춘다. 또 $K_{\max}$와 거의 무관하게 적은 수의 성분으로 같은 수준 이상의 적합도를 낸다. 반면 소표본에서 약하고, 계산 비용이 $K_{\max}$에 대해 크게 늘며, 이동 후보를 고르는 규칙이 경험적이라는 한계가 있다. 다음 단계로는 이동 없이 모든 갱신이 닫힌꼴인 "켤레 구조" 버전(형상 β를 격자 위의 범주형 사후로 두는 방식)을 같은 실험으로 비교할 계획이다. 이 버전은 아직 평가하지 않았다.

재현. 모든 그림과 표는 `experiments/s14_report.py`와 `s14_tables.py`로 다시 만들 수 있다(시드 고정). 환경은 sklearn 1.9.1, scipy 1.18.1, numpy 2.5.4, rdt 2.1.0이다.

References

[1] H. Ishwaran and L. F. James. Gibbs sampling methods for stick-breaking priors. *JASA*, 96(453):161–173, 2001.

[2] L. Xu, M. Skoularidou, A. Cuesta-Infante, and K. Veeramachaneni. Modeling tabular data using conditional GAN. *NeurIPS*, 2019.

[3] M. C. Hughes and E. B. Sudderth. Memoized online variational inference for Dirichlet process mixture models. *NIPS*, 2013.