변분 일반화 정규 혼합모형(VGGMM)을 이용한 첨도 인식 모드별 정규화: 방법 설명

1 요약과 기여

CTGAN은 연속형 열을 신경망에 넣기 전에 모드별 정규화를 한다. 열마다 Bayesian Gaussian Mixture(BGM)를 적합하고, 각 값을 "어느 성분에서 왔는가"(범주)와 "그 성분 안에서 어디쯤인가"(연속값)로 나눈다. 이 문서는 BGM의 Gaussian 성분을 일반화 정규분포(Generalized Gaussian Distribution, GGD)로 바꾼 변분 추론 알고리즘(이하 VGGMM)을 설명한다. GGD는 형상 모수 β로 첨도를 조절한다.

이 연구에서 쓰는 수학적·데이터과학적 기법은 다음과 같다.

1. GGD 성분 혼합모형. 형상 모수 β와 첨도는 1:1로 대응한다(식 (2)).
2. 디리클레 과정(DP)의 stick-breaking 사전. 성분 가중치를 정하고, 불필요한 성분의 가중치를 0으로 보낸다.
3. 척도의 재매개화 $\tau = \alpha^{-\beta}$. 이렇게 두면 Gamma 사전이 켤레가 되어 $q(\tau)$를 닫힌꼴로 갱신할 수 있다.
4. 평균장 변분 추론(좌표 상승, CAVI)과 증거하한(ELBO). 위치 μ와 형상 β는 점추정한다(VB-EM).
5. 성분별 축약 목적함수 $F_k(\mu, \beta)$. τ를 적분해서 얻으며, μ와 β를 1차원 탐색으로 갱신해도 ELBO가 줄지 않음을 보장한다.
6. β에 따라 의미가 바뀌지 않는 척도 사전 $b_0(\beta) = a_0 c^{\beta}$.
7. ELBO로 검증하는 구조 이동(병합·삭제·재정렬). 국소 최적에서 벗어나게 해서, 성분 수가 $K_{\max}$에 끌려가지 않고 데이터로 정해지게 한다.
8. 분위수 기반 정규화 폭 h_k. 기존 4σ 규칙을 일반화한 것으로, $\beta = 2$이면 3.89σ가 된다.
9. 정수형 열의 디퀀타이즈(dequantization).
10. 검증 장치: $\beta = 2$로 고정하면 sklearn BGM과 같은 갱신이 됨을 보이는 명제(명제 1).

2 배경: BGM 모드별 정규화와 그 한계

CTGAN의 전처리(rdt `ClusterBasedNormalizer`)는 다음 순서로 동작한다.

1. 열 하나에 $K_{\max} = 10$인 BGM을 적합한다. 가중치 사전은 DP stick-breaking이고 집중 모수는 $\gamma = 0.001$이다.
2. 가중치가 0.005보다 큰 성분을 "유효"로 표시한다.

3. 각 값 x에 대해 사후확률에 따라 성분 k를 하나 뽑고, $u = (x - \mu_k)/(4\sigma_k)$를 계산한 뒤 ± 0.99에서 자른다.

4. 출력은 $(u,\ \text{one-hot}(k))$이다. 생성기는 u를 `tanh`로, k를 `softmax`로 만든다.

이 방식에는 세 가지 한계가 있다.

- **Gaussian 가정.** 꼬리가 두껍거나(첨도가 큼) 윗부분이 평평한(첨도가 작음) 봉우리를 Gaussian 여러 개를 겹쳐 흉내 낸다. 그래서 성분 수가 늘고 밀도 추정도 부정확해진다.
- **4σ 폭.** "99.99%가 $[-1, 1]$ 안에 든다"는 기준은 Gaussian에서만 맞다. 꼬리가 두꺼우면 많이 잘리고, 평평하면 `tanh` 구간을 낭비한다.
- **성분 수.** 관측해 보면 BGM의 유효 성분 수는 $K_{\max}$를 늘릴수록 같이 늘어난다(§11).

3 모형

3.1 일반화 정규분포(GGD)와 첨도

위치 μ, 척도 $\alpha > 0$, 형상 $\beta > 0$인 GGD의 밀도는 다음과 같다.

$$p(x \mid \mu, \alpha, \beta) = \frac{\beta}{2\alpha\,\Gamma(1/\beta)} \exp\Big\{ - \Big(\frac{|x - \mu|}{\alpha} \Big)^{\beta} \Big\}. \tag{1}$$

표준편차는 $\sigma = \alpha\sqrt{\Gamma(3/\beta)/\Gamma(1/\beta)}$이고, 초과첨도는 β 하나로 정해진다.

$$\kappa(\beta) = \frac{\Gamma(5/\beta)\,\Gamma(1/\beta)}{\Gamma(3/\beta)^2} - 3. \tag{2}$$

$\beta = 2$이면 Gaussian($\kappa = 0$), $\beta = 1$이면 Laplace($\kappa = 3$)이고, $\beta \to \infty$이면 균등분포($\kappa \to -1.2$)에 가까워진다. 따라서 β를 추정하는 것은 곧 첨도를 추정하는 것이다.

비유. 성분 하나를 산 하나로 생각하면, μ는 산의 위치, α는 산의 폭, β는 산의 모양이다. β가 작으면 뾰족한 바위산이고 β가 크면 평평한 고원이다.

3.2 재매개화와 혼합모형

$\tau = \alpha^{-\beta}$로 두면 밀도는

$$p(x \mid \mu, \tau, \beta) = \frac{\beta\,\tau^{1/\beta}}{2\Gamma(1/\beta)} \exp\{-\tau |x - \mu|^{\beta}\} \tag{3}$$

이 된다. τ에 대해서는 $\tau^{1/\beta} e^{-\tau(\cdot)}$ 꼴이므로 Gamma 분포와 켤레다(§4.2).

데이터는 내부적으로 $z = (x - m)/s$로 표준화한다. m은 평균, s는 표준편차다. 이렇게 하면 $|z - \mu|^{\beta}$의 크기가 β에 크게 좌우되지 않는다.

혼합모형은 다음과 같다($k = 1, \dots, K_{\max}$).

$$v_k \sim \text{Beta}(1, \gamma), \qquad \pi_k = v_k \textstyle\prod_{j<k}(1 - v_j), \tag{4}$$

$$c_n \mid \pi \sim \text{Cat}(\pi), \qquad \tau_k \mid \beta_k \sim \text{Gamma}\big(a_0,\ b_0(\beta_k)\big), \qquad b_0(\beta) = a_0\, c^{\beta}, \tag{5}$$

$$z_n \mid c_n = k \sim \text{GGD}(\mu_k, \tau_k, \beta_k). \tag{6}$$

비유(*stick-breaking*). 길이 1인 막대를 앞사람부터 차례로 잘라 간다. 앞 성분들이 데이터를 많이 맡아 막대를 많이 가져가면, 뒤 성분 몫은 거의 남지 않는다. γ가 작을수록 "적은 수의 성분만 쓰라"는 압력이 강해진다.

척도 사전. $b_0(\beta) = a_0 c^{\beta}$로 두면 $\mathbb{E}[\tau] = c^{-\beta}$, 즉 "$\alpha$의 사전 추측값은 c"가 되고, 이 뜻은 β와 관계없이 같다. 반대로 b_0를 상수로 두면, 좁은 성분에서 데이터 쪽 값 S_k(아래 식 (13))가 b_0보다 몇 자리 작아져 사전에 묻힌다. 실제로 참값 $\beta = 8$인 성분이 1.9로 추정되었다.

3.3 근사 분포

평균장 분해를 쓴다.

$$q = \prod_k q(v_k) \prod_k q(\tau_k) \prod_n q(c_n), \tag{7}$$

$$q(v_k) = \mathrm{Beta}(\gamma_{1k}, \gamma_{2k}), \qquad q(\tau_k) = \mathrm{Gamma}(a_k, b_k), \qquad q(c_n) = \mathrm{Cat}(r_n). \tag{8}$$

μ_k와 β_k는 분포 없이 점추정한다. 따라서 이 방법은 부분적으로 베이지안인 VB-EM이다. ELBO $\mathcal{L}$은 $\log p(X \mid \mu, \beta)$의 하한이다.

4 추론: 좌표 상승 변분 추론

ELBO는 다음과 같다.

$$\begin{aligned} \mathcal{L} &= \mathbb{E}_q[\log p(z, c, v, \tau \mid \mu, \beta)] - \mathbb{E}_q[\log q] \\ &= \underbrace{\textstyle\sum_{n,k} r_{nk} \mathbb{E}[\log p(z_n \mid k)]}_{\text{설명력}} - \underbrace{\text{KL 항들}}_{\text{복잡도 벌점}} + (\text{책임도 엔트로피}). \end{aligned} \tag{9}$$

매 반복마다 아래 블록을 차례로 갱신한다. 각 블록은 다른 블록을 고정한 채 $\mathcal{L}$을 최대화하거나, 적어도 줄이지 않는다.

비유. 등산객이 동서와 남북 방향을 번갈아 가며 한 걸음씩 오르는 것과 같다(좌표 상승). 높이(ELBO)는 절대 내려가지 않는다.

4.1 E-step: 책임도

$$\log \rho_{nk} = \mathbb{E}[\log \pi_k] + \log \beta_k - \log 2 - \log \Gamma(1/\beta_k) + \frac{\psi(a_k) - \log b_k}{\beta_k} - \frac{a_k}{b_k} |z_n - \mu_k|^{\beta_k}, \tag{10}$$

$$r_{nk} = \rho_{nk} \big/ \textstyle\sum_j \rho_{nj}, \tag{11}$$

$$\mathbb{E}[\log \pi_k] = \psi(\gamma_{1k}) - \psi(\gamma_{1k} + \gamma_{2k}) + \textstyle\sum_{j<k} \big[\psi(\gamma_{2j}) - \psi(\gamma_{1j} + \gamma_{2j})\big]. \tag{12}$$

여기서 ψ는 digamma 함수이고, $\mathbb{E}[\log \tau] = \psi(a) - \log b$, $\mathbb{E}[\tau] = a/b$이다.

비유. 각 데이터 점이 성분마다 "나는 너에게 몇 % 속한다"고 투표한다. 투표율이 r_{nk}다.

4.2 M-step

$N_k = \sum_n r_{nk}$로 둔다.

(1) 가중치(BGM과 동일). $\gamma_{1k} = 1 + N_k$, $\gamma_{2k} = \gamma + \sum_{j>k} N_j$.

(2) 척도: Gamma 켤레, 닫힌꼴. μ, β를 고정하면 $\prod_n p(z_n \mid \tau_k)^{r_{nk}} \propto \tau_k^{N_k/\beta_k} \exp(-\tau_k S_k)$이고, 이는 Gamma 커널이다. 따라서

$$S_k = \sum_n r_{nk} |z_n - \mu_k|^{\beta_k}, \qquad a_k = a_0 + \frac{N_k}{\beta_k}, \qquad b_k = b_0(\beta_k) + S_k. \tag{13}$$

$\beta = 2$이면 S_k는 가중 제곱합이 되어, BGM의 분산 갱신과 같은 식이다.

(3) 축약 목적함수. $q(\tau_k)$를 최적값으로 두고 τ_k를 적분하면, 성분 k의 ELBO 기여분은 μ, β만의 함수가 된다.

$$\begin{aligned} F_k(\mu, \beta) = N_k \big[\log \beta - \log 2 - \log \Gamma(1/\beta) \big] + a_0 \log b_0(\beta) - \log \Gamma(a_0) \\ + \log \Gamma(a_k) - a_k \log \big(b_0(\beta) + S_k(\mu, \beta) \big). \end{aligned} \tag{14}$$

(4) 위치 μ. β를 고정하면 a_k는 μ와 무관하므로, F_k를 최대화하는 것은 S_k를 최소화하는 것과 같다.

$$\mu_k = \arg\min_{\mu} \sum_n r_{nk} |z_n - \mu|^{\beta_k}. \tag{15}$$

$\beta = 2$이면 가중평균, $\beta = 1$이면 가중중앙값이고, 그 밖에는 1차원 Brent 탐색으로 구한다.

(5) 형상 β. μ를 고정하고 $\log \beta$ 공간에서 F_k를 최대화한다.

$$\beta_k = \arg\max_{\beta \in [0.3,\, 10]} F_k(\mu_k, \beta). \tag{16}$$

계산은 bounded Brent 탐색으로 한다. 한 번의 M-step에서는 현재 β의 1/2배에서 2배 사이만 탐색한다.

(6) 수락 규칙. (4)와 (5)는 F_k가 실제로 커질 때만 새 값을 받아들인다. 그래서 수치 탐색을 써도 ELBO가 줄지 않는다.

비유. 투표 결과를 보고 각 산(성분)이 자기 위치·폭·모양을 다시 맞춘다. 폭은 공식으로 바로 계산되고(켤레), 위치와 모양은 조금씩 움직여 보며 더 나은 쪽을 고른다.

4.3 ELBO와 단조성

M-step 직후에는 많은 항이 서로 지워져서, ELBO가 다음처럼 간단해진다.

$$\mathcal{L} = \sum_k F_k - \sum_{n,k} r_{nk} \log r_{nk} + \sum_k \big[\log B(\gamma_{1k}, \gamma_{2k}) - \log B(1, \gamma) \big] - N \log s. \tag{17}$$

마지막 항 $-N \log s$는 표준화를 되돌리는 야코비안이다. E-step은 $q(c)$에 대한 정확한 최대화이고, (1)·(2)도 정확한 최대화이며, (4)·(5)는 개선될 때만 받아들인다. 따라서 $\mathcal{L}$은 반복마다 줄지 않는다. 수치로도 이 축약식이 전체 ELBO와 10^{-12} 이내로 같음을 확인했다.

명제 1 (BGM으로의 환원)**.** $\beta_k \equiv 2$로 고정하고, 척도 사전을 $a_0 = \nu_0/2 = 1/2$, $b_0 = \widehat{\mathrm{Var}}(z)$(상수)로 두자. 또 *BGM*의 평균 정밀도 사전 $\kappa_0 \to 0$이라 하자. 그러면 같은 책임도에서 *VGGMM*의 *M-step*은 *BGM*의 *M-step*과 같다. *E-step* 점수는 정확히 $1/(2\kappa_k)$만큼 차이 난다($\kappa_k = \kappa_0 + N_k$). 이 차이는 *BGM*이 μ에 사후분포를 두기 때문에 생기는 분산항이다.

수치 확인 결과, 평균·분산의 차이는 10^{-14} 수준이었고, 점수 차이에서 $1/(2\kappa_k)$를 뺀 나머지는 10^{-14} 이하였다.

5 구조 이동: 성분 수를 데이터가 정하게 하기

문제. 위 좌표 상승만 쓰면 국소 최적에 갇힌다. 예를 들어 한 덩어리를 두 성분이 반씩 맡으면, 둘 다 N_k가 커서 가중치가 줄어들 압력이 생기지 않는다. 실제로 이동 없이 학습하면 유효 성분 수가 $K_{\max} = 10, 20, 30$에서 $10, 19, 28$이었다. 반면 참 라벨로 시작한 5성분 해의 ELBO는 kmeans로 시작한 10성분 해보다 63 높았다. 즉 목적함수는 이미 5성분을 선호하고, 문제는 최적화였다.

이동의 정의. 현재 상태에서 다음 세 가지 후보를 만든다.

- **재정렬:** N_k가 큰 순서로 성분 순서를 바꾼다. stick-breaking에서는 큰 성분이 앞에 있을 때 ELBO가 높다.
- **병합:** 평균 순서상 이웃한 성분 i, j의 책임도를 $r_{\cdot i} \leftarrow r_{\cdot i} + r_{\cdot j}$, $r_{\cdot j} \leftarrow 0$으로 합친다.
- **삭제:** 성분 j를 빼고, 나머지 성분의 점수로 책임도를 다시 정규화한다.

병합과 삭제 뒤에는 재정렬을 함께 하고, 바뀐 성분의 β는 2에서 다시 시작한다.

수락 규칙. 이동 없이 T번 더 학습한 ELBO를 $\mathcal{L}_{\text{ctrl}}$(대조군)이라 하고, 이동 후 T번 학습한 ELBO를 $\mathcal{L}_{\text{cand}}$라 하자. 다음일 때만 이동을 받아들인다.

$$\mathcal{L}_{\text{cand}} > \mathcal{L}_{\text{ctrl}} + \delta N \qquad (T = 20,\ \delta = 10^{-4}). \tag{18}$$

후보 순서는 다음과 같다.

1. 재정렬
2. 겹침 $O_{ij} = \sum_n \sqrt{r_{ni} r_{nj}} / \sqrt{N_i N_j}$이 큰 이웃 병합 3개
3. 가중치가 작은 성분 삭제 3개
4. 위 후보가 모두 실패하면, 나머지 이웃 병합과 삭제 전부

처음 받아들여진 이동에서 라운드를 다시 시작하고, 받아들여지는 이동이 없으면 탐색을 끝낸 뒤 수렴할 때까지 좌표 상승을 이어 간다.

후처리가 아닌 이유. 모든 이동은 같은 목적함수 $\mathcal{L}$을 올릴 때만 받아들여진다. 또 이동 뒤에도 같은 좌표 상승을 계속한다. 따라서 이동은 "더 높은 국소 최적으로 옮겨 가는 최적화 단계"이다. 참 성분 수 같은 외부 정보는 어디에도 쓰지 않는다. 다만 어떤 후보를 시도할지 고르는 규칙은 경험적이다. 비슷한 접근으로 Hughes & Sudderth(2013)의 merge/delete 이동과 Kurihara 외(2007)의 크기순 재정렬이 있다.

비유. 등산객이 작은 봉우리에 갇혔을 때, 이웃 능선으로 건너가 잠깐 올라가 본다. 원래 자리에서 같은 시간만큼 오른 것보다 더 높을 때만 그쪽으로 옮긴다.

6 전처리기: 정규화와 역변환

대표값. 원래 단위로 되돌린 값은 다음과 같다.

$$\hat{\mu}_k = m + s\mu_k, \qquad \hat{\alpha}_k = s\,(b_k/a_k)^{1/\beta_k}, \qquad \hat{\sigma}_k = \hat{\alpha}_k \sqrt{\Gamma(3/\beta_k)/\Gamma(1/\beta_k)}.$$

이는 "정밀도의 사후평균을 대입"하는 규칙으로, BGM의 `covariances_` $= 1/\mathbb{E}[\lambda]$와 같은 규칙이다.

분위수 반폭. $X \sim \mathrm{GGD}(\mu, \alpha, \beta)$ 이면 $Y = (|X-\mu|/\alpha)^{\beta} \sim \mathrm{Gamma}(1/\beta, 1)$ 이다. 따라서 확률 $1-\varepsilon$ 이 들어가는 반폭은

$$h_k = \hat{\alpha}_k \Big[P^{-1}\big(1/\beta_k,\, 1-\varepsilon\big) \Big]^{1/\beta_k}, \qquad \varepsilon = 10^{-4} \tag{19}$$

이다. P^{-1} 은 정규화 하위 불완전감마함수의 역함수다. $\beta = 2$ 이면 $h = 3.89\sigma$ 가 되므로, rdt의 "4σ = 99.99%" 규칙을 모든 β 로 넓힌 것이다.

변환과 역변환. 성분은 rdt와 같은 방식으로 고른다. 확률 $r_{nk} + 10^{-6}$ 에 비례해 k를 뽑는다. 변환은 $u = \mathrm{clip}\big((x-\hat{\mu}_k)/h_k,\ \pm 0.99\big)$ 이고, 역변환은 $x = \mathrm{clip}(u, \pm 1)\, h_k + \hat{\mu}_k$ 이다.

비유. 성분마다 자의 눈금 길이를 그 산의 모양에 맞춘다. 뾰족한 산에는 긴 자를, 평평한 산에는 짧은 자를 쓴다.

디퀀타이즈. 값이 모두 정수인 열은 연속 밀도로 적합하면 문제가 생긴다. 한 정수값에 성분이 붕괴하면 우도가 무한대로 발산하기 때문이다. 실제로 $\beta \to 0.3$, $\alpha \approx 10^{-16}$ 인 점질량 성분이 생겼다. 그래서 학습과 변환에서는 $\tilde{x} = x + U, U \sim \mathrm{Unif}(-\tfrac{1}{2}, \tfrac{1}{2})$ 을 쓰고, 역변환에서는 반올림한다. 정수 x의 확률은 $P(x) = \int_{x-1/2}^{x+1/2} p(t)\,dt$ 이므로, Jensen 부등식에 의해 $\mathbb{E}_U[\log p(x+U)] \le \log P(x)$ 이다(Theis 외, 2016).

비유. 정수 눈금마다 폭 1짜리 칸을 고르게 채워서, 점들을 매끄러운 면으로 바꾼다.

7 알고리즘 전체

입력: 열 $x_{1:N}$, $K_{\max}$. **출력:** $\{\hat{\pi}_k, \hat{\mu}_k, \hat{\alpha}_k, \beta_k, h_k\}$, 유효 성분, 정규화된 (u, k).

1. 값이 모두 정수이면 디퀀타이즈한다. 그다음 $z = (x-m)/s$ 로 표준화한다.
2. kmeans로 초기 책임도 r을 만든다(BGM과 같음). 초기값은 $\beta_k = 2$ 이고, M-step을 한 번 한다.
3. E-step과 M-step(가중치 $\to \mu \to \beta \to \tau$)을 반복한다. $|\Delta\mathcal{L}| < 10^{-3}$ 이거나 100회가 되면 멈춘다.
4. 구조 이동 탐색을 한다(§5). 받아들여지는 이동이 없을 때까지 라운드를 반복한다.
5. 수렴할 때까지 3단계를 다시 반복한다.
6. $\hat{\pi}_k = \mathbb{E}[v_k]\prod_{j<k}(1-\mathbb{E}[v_j])$ 를 정규화하고, $\hat{\pi}_k > 0.005$ 인 성분을 유효로 표시한다. h_k 를 계산한다.
7. 정규화와 역변환은 §6을 따른다.

8 BGM과의 흐름 비교

단계	BGM (sklearn / rdt)	VGGMM
입력 처리	원래 단위 그대로	표준화, 정수 열은 디퀀타이즈
초기화	kmeans 책임도	같음
가중치	DP stick-breaking, $q(v)$=Beta	같음
성분 분포	Gaussian	GGD (형상 β)
척도 사후	Wishart(1차원: Gamma), λ	Gamma, $\tau = \alpha^{-\beta}$
위치	Normal 사후 $q(\mu)$	점추정 (가중 L_β 중심)
형상	2로 고정	추정 (F_k 최대화)
E-step 점수	Gaussian 기대 로그밀도	GGD 기대 로그밀도
ELBO	Gaussian · Wishart	GGD · Gamma, 축약식 $\sum F_k$
구조 탐색	없음	병합 · 삭제 · 재정렬 (ELBO 검증)
대표 폭	$\sigma = \mathbb{E}[\lambda]^{-1/2}$	같은 규칙, $\hat{\sigma}_k$
정규화 폭	4σ	h_k (99.99% 분위수)

개선점	해결한 한계	근거 (§11)
GGD 성분과 β 추정	Gaussian 가정	비정규 시나리오에서 KL이 BGM보다 15–25배 작음. β 복원 오차 3% 이내
구조 이동	성분 수가 $K_{\max}$를 따라감	유효 성분 수: 이동 없이 10/19/28, 이동 있으면 5/5/5
h_k 정규화	4σ 클리핑	$\beta = 0.5$에서 잘림 비율 1.14% → 0.03%
디퀀타이즈	정수 열의 점질량	점질량 성분 18 → 0개, 역변환 정확도 100%
명제 1	정당성 검증	sklearn과 10^{-14} 수준으로 일치

9 신경망과의 관계

VGGMM은 신경망이 아니며, 경사하강법이나 역전파도 쓰지 않는다. 학습은 확률모형의 좌표상승 변분 추론이다. 신경망 학습에 익숙한 독자를 위해 대응 관계를 정리하면 다음과 같다.

신경망 용어	VGGMM에서 해당하는 것
손실함수	$-\mathcal{L}$ (음의 ELBO)
순전파	E-step: 현재 모수로 책임도 r 계산
가중치 갱신	M-step: 닫힌꼴(가중치, τ)과 1차원 탐색(μ, β). 학습률이 없다
손실 단조 감소	ELBO 단조 증가가 구조적으로 보장됨
정규화(regularization)	사전분포의 KL 항, stick-breaking의 γ
구조 탐색 / 가지치기	병합 · 삭제 이동 (ELBO로 검증)

CTGAN의 신경망과 만나는 지점은 전처리의 출력 (u, one-hot(k)) 이다. VGGMM은 생성기가 학습할 표현을 바꿀 뿐, GAN 구조나 학습 방법은 바꾸지 않는다.

10 하이퍼파라미터

이름	기본값	의미와 근거
$K_{\max}$	10	성분 수 상한 (rdt 기본값)
γ	0.001	stick-breaking 집중 모수 (rdt 기본값)
a_0	0.5	τ 사전 shape. sklearn의 $\nu_0 = 1$에 해당
c	0.1	표준화 단위에서 α의 사전 추측값. 인공 데이터에서 β 복원을 보고 선택
β 범위	$[0.3, 10]$	수치 안정 범위
β 초기값	2	Gaussian에서 시작
$N_{\min}$	5	N_k가 이보다 작으면 β를 갱신하지 않음
T	20	이동 후보 하나당 학습 반복 수
δ	10^{-4}	이동 수락 문턱 (표본당 ELBO 증가량)
후보 수	3+3	우선 시도할 병합·삭제 후보 수
수렴 기준	10^{-3}, 100회	sklearn 기본값
ε	10^{-4}	정규화 폭의 꼬리 확률 (rdt의 99.99% 의도)
유효 문턱	0.005	rdt 기본값

11 실험 근거

환경은 sklearn 1.9.1, scipy 1.18.1, numpy 2.5.4, rdt 2.1.0이다. 표시가 없는 항목은 연구자 PC에서 재현했다. †는 개발 환경에서만 측정한 결과로, 재현을 기다리는 중이다.

1. **BGM 환원(명제 1).**
   - M-step 차이: 1.5×10^{-14}
   - E-step 점수 차이에서 $1/(2\kappa_k)$를 뺀 나머지: 6.7×10^{-15}
   - 20회 반복 후: 가중치 차이 3.9×10^{-4}, 평균 차이 0.0036σ
   - ELBO 감소: 0회
2. **β 복원.** 성분 1개, $N = 10^4$에서 참값 0.5, 1, 2, 4, 8에 대해 추정값은 0.503, 0.989, 1.989, 3.964, 7.764였다.
3. **성분 수(GGD 5개 혼합, $\beta = 0.8, 1, 2, 4, 8$).**
   - $K_{\max} = 10, 20, 30$ 모두 유효 성분 5개, 같은 ELBO($-28{,}690.36$)
   - 추정 β: 0.86, 1.03, 2.14, 3.89, 8.52
   - 평가 로그우도: VGGMM -2.8607, 참 밀도 -2.8596, BGM -2.888
4. **정규화.** 단일 GGD에서 rdt BGM은 성분을 9–10개 썼다. 4σ 잘림 비율은 $\beta = 0.5$에서 1.14%, $\beta = 1$에서 0.35%였고, h_k는 0.03% 이하였다.
5. **adult(디퀀타이즈, $K_{\max} = 10$).** 연속 열 6개 모두 평가 로그우도가 BGM 이상이었고, 성분 수는 5개 열에서 같거나 적었다.
6. **adult, $K_{\max} = 10/20/30$†.**
   - age 유효 성분: BGM 10/19/28, VGGMM 5/4/5

- VGGMM이 $K_{\max}$를 그대로 따라가는 열은 없었다
- 반복값이 많은 정수 열(hours-per-week, capital-gain)은 $K_{\max}$를 늘릴수록 성분 수가 늘었고, ELBO와 로그우도도 함께 개선되었다

7. **체계적 비교**†**.** 5개 시나리오 $\times$ $N \in \{10^3, 5\cdot10^3, 2\cdot10^4\}$ $\times$ 시드 3개, KL은 참 분포 기준이다.
   - 꼬리가 두꺼운 혼합, 평평한 혼합, 섞인 혼합: VGGMM 승률 100%, KL 비율(BGM/VGGMM) 중앙값 15–25
   - 정규 혼합: 평균 KL은 BGM 0.0031, VGGMM 0.0038로 허용 범위 안이며, $N \geq 5000$에서는 VGGMM이 더 낮음
8. **디퀀타이즈.**
   - 디퀀타이즈 끔: 점질량 성분이 열별로 $[1, 0, 8, 2, 1, 6]$개
   - 디퀀타이즈 켬: 0개, 역변환으로 원래 정수를 100% 복원
9. **속도.** 최적화 후 1.72–1.86배 빨라졌지만, 여전히 BGM보다 약 10–20배 느리다.

12 한계와 후속 연구

- **소표본.** $N = 1000$에서 정규 혼합(KL 0.0103 대 0.0073)과 많이 겹친 혼합(0.0190 대 0.0127)은 BGM보다 나빴다. 겹친 혼합에서는 2성분으로 과소적합했다. 후보 해결책은 β에 약한 사전을 두는 것(MAP)이다.
- **부분 베이지안.** μ, β를 점추정하므로 이 둘의 불확실성을 표현하지 못하고, 오컴 벌점도 약하다. 대안으로 β를 이산 격자 위의 사후분포로 두는 방법이 있다.
- **이동 후보 선택.** 수락 기준은 원리적이지만, 어떤 후보를 시도할지 고르는 규칙은 경험적이다. 최종 해도 $K_{\max}$에 따라 조금 달라진다(예: fnlwgt 6/7/9).
- **이산값 열.** 반복값이 많은 정수 열에서는 성분 수가 $K_{\max}$와 함께 늘 수 있다. 자주 나오는 값을 별도 범주로 떼어 내는 방법을 검토할 수 있다.
- **속도.** 뉴턴형 갱신이나 컴파일(numba 등)이 필요하다.
- **선택의 투명성.**
  - $c = 0.1$은 같은 인공 데이터에서 골랐다.
  - BGM 일치 검사 중 장기 반복 비교는 20회 시점 비교로 바꿨다. $1/(2\kappa_k)$ 차이가 반복마다 누적되기 때문이다.

References

[1] C. M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006. (10장, 변분 Gaussian 혼합)

[2] J. Sethuraman. A constructive definition of Dirichlet priors. *Statistica Sinica*, 4:639–650, 1994.

[3] D. M. Blei and M. I. Jordan. Variational inference for Dirichlet process mixtures. *Bayesian Analysis*, 1(1):121–143, 2006.

[4] K. Kurihara, M. Welling, and N. Vlassis. Accelerated variational Dirichlet process mixtures. *NIPS 19*, 2007.

[5] M. C. Hughes and E. B. Sudderth. Memoized online variational inference for Dirichlet process mixture models. *NIPS 26*, 2013.

[6] L. Xu, M. Skoularidou, A. Cuesta-Infante, and K. Veeramachaneni. Modeling tabular data using conditional GAN. *NeurIPS 32*, 2019.

[7] S. Nadarajah. A generalized normal distribution. *Journal of Applied Statistics*, 32(7):685–694, 2005.

[8] L. Theis, A. van den Oord, and M. Bethge. A note on the evaluation of generative models. *ICLR*, 2016.

[9] F. Pedregosa et al. Scikit-learn: Machine learning in Python. *JMLR*, 12:2825–2830, 2011.